课程安排

Pandas

1. 基本操作
    - 数据基本操作
    - 运算
    - 绘图
    - 文件读取
2. 高级处理
    - 缺失值处理

- 数据离散化
    - 合并
- 交叉表和透视表
    - 分组聚合
- 知识树

3 统计运算

3.1 describe

`data.describe()`

- 能够直接得出很多统计结果,`count`,`mean`,`std`,`min`,`max` 等

3.2 统计函数

函数	作用
max（）、min（）	最大值、最小值
var（）、std（）	方差、标准差
median（）	中位数
idxmax（）、idxmin（）	最大（小）值的位置

3.3 累计统计函数

函数	作用
cumsum	**计算前1/2/3/…/n个数的和**
cummax	计算前1/2/3/…/n个数的最大值
cummin	计算前1/2/3/…/n个数的最小值
cumprod	计算前1/2/3/…/n个数的积

4 自定义运算

- `对象.apply(func,axis=)`
    - func:自定义函数
    - axis=0:默认是列，axis=1为行进行运算
- def func():

执行代码

return

5.5 Pandas画图

`DataFrame.plot`(*kind='line'*)

- kind : str，需要绘制图形的种类
  - **'line' : line plot (default)**
  - 'bar' : vertical bar plot
  - 'barh' : horizontal bar plot
    - 关于"barh"的解释：
    - http://pandas.pydata.org/pandas-docs/stable/reference/api/pandas.DataFrame.plot.barh.html
  - 'hist' : histogram
  - 'pie' : pie plot
  - 'scatter' : scatter plot

5.6 文件读取与存储

1 CSV

- pd.read_csv(路径,)
- DataFrame.to_csv(path_or_buf=None, sep=', ', columns=None, header=True, index=True, mode='w', encoding=None)
  - path_or_buf :文件路径
  - sep :分隔符，默认用","隔开
  - columns :选择需要的列索引
  - header :boolean or list of string, default True,是否写进列索引值
  - index:是否写进行索引
  - mode:'w'：重写, 'a' 追加
- 举例：保存读取出来的股票数据
  - 保存'open'列的数据，然后读取查看结果

2 HDF5

pd.read_hdf(路径,key=)

pd.to_hdf(路径,key=)

优先选择使用HDF5文件存储

- HDF5在存储的时候支持压缩， **使用的方式是blosc，这个是速度最快** 的也是pandas默认支持的
- 使用压缩可以 **提磁盘利用率，节省空间**
- HDF5还是跨平台的，可以轻松迁移到hadoop 上面

3 JSON

pd.read_json('路径',orient=,lines=True)

- 'split' : dict like {index -> [index], columns -> [columns], data -> [values]}

    - split 将索引总结到索引，列名到列名，数据到数据。将三部分都分开了
- 'records' : list like [{column -> value}, ... , {column -> value}]
    - records 以`columns：values`的形式输出
- 'index' : dict like {index -> {column -> value}}
    - index 以`index：{columns：values}...`的形式输出
- 'columns' : dict like {column -> {index -> value}}

  ,默认该格式
    - colums 以`columns:{index:values}`的形式输出
- 'values' : just the values array
    - values 直接输出值

对象.to_json('路径',orient=,lines=)

5.7 高级处理-缺失值处理

1 如何处理nan

1. 删除
2. 补足

   处理缺失值

   1. 判断是否有缺失值

      isnull()有缺失值

      notnull()没有缺失值

      跟着np.any 和 np.all()
   2. 解决缺失值

      2.1删除

      dropna()

      2.2 补足缺失值

      对象.fillna(mean(),inplace=))
   3. 如何缺失值是其他值'?'

      将'?'替代成nan

      df.replace(to_replace=, value=)

      - to_replace:替换前的值
      - value:替换后的值

5.8 高级处理-数据离散化

什么是数据离散化

将值域划分为若干个离散的区间，最后用不同的符号或整数 值代表落在每个子区间中的属性值

为什么要离散化

1. 算法需要

2. 减少连续值得个数

如何离散化

- pd.qcut(data, q):
- ```
  qcut.value_counts()
  ```
- pd.cut(data,bins)

  bins 自己指定分组区间

3.3 股票涨跌幅分组数据变成one-hot编码

防止算法将类别型数据理解成数值型

如何转成one-hot 编码

pd.get_dummies(data,prefix=None)

prefix:分组名字

5.9 高级处理-合并

应用场景: 你的数据由多张表组成，那么有时候需要将不同的内容合并在一起分析

1 pd.concat实现数据合并

pd.concat([data1, data2], axis=1)

- 按照行或列进行合并,axis=0为列索引，axis=1为行索引

2 pd.merge

pd.merge(left,right,how,on=[,])

- 可以指定按照两组数据的共同键值对合并或者左右各自
- `left` : DataFrame
- `right` : 另一个DataFrame
- `on` : 指定的共同键
- how:按照什么方式连接

5.10 高级处理-交叉表与透视表

交叉表 **交叉表用于计算一列数据对于另外一列数据的分组个数**(个数)

pd.crosstab(value1, value2)

透视表：**透视表是将原有的DataFrame的列分别作为行索引和列索引，然后对指定的列应用聚集函数**(比例)

data.pivot_table(B,index=[A])

5.11 高级处理-分组与聚合

1 什么分组与聚合
  ```

2 分组API

对象.groupby(key=,as_index=)[''].mean()/max()